

شکل ۲-۱: طبقه‌بندی روش‌های یادگیری پیوسته در مدل‌های بینایی بزرگ و بینایی-زبان [۲۶]

۲-۴-۲ روش‌های مبتنی بر تنظیم

در این روش، مدل از مکانیزم‌هایی مانند جریمه یا محدودسازی برای حفظ اطلاعات قبلی استفاده می‌کند. هدف این است که پارامترهایی که در یادگیری گذشته مهم بوده‌اند، هنگام آموزش جدید کمتر تغییر کنند. در این روش، در صورت حجم زیاد وظایف، اثربخشی کاهش می‌یابد [۲۶].


۳-۴-۲ روش‌های مبتنی بر تقطیر دانش

مدل دانش خود را از مدل‌های قبلی یا معلم یاد می‌گیرد؛ این دانش می‌تواند مبتنی بر داده‌های جدید، قدیمی یا داده‌های شبه‌واقعی باشد. در این روش، توجه به مواردی مانند حساسیت به دقت مدل معلم و انتخاب صحیح داده‌ها برای تقطیر خاثر اهمیت است [۲۶].

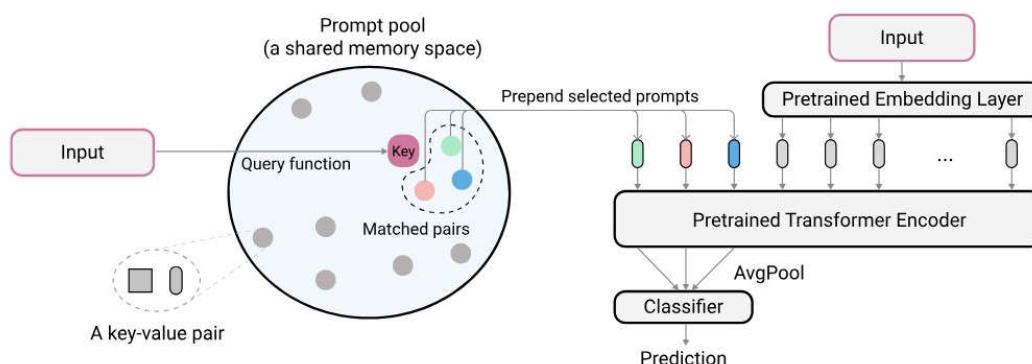
۴-۴-۲ روش‌های مبتنی بر معماری

در این رویکرد، معماری مدل برای جذب وظایف جدید، بدون تداخل با وظایف قبلی، تغییر می‌کند؛ مانند افزودن پیمانه^{۳۶} استفاده از تطبیق‌دهنده‌ها و ژنگ و همکاران [۲۶]، با بررسی روش‌های مختلف ارائه‌شده در این رویکرد، طبقه‌بندی مطابق با شکل ۲-۲ ارائه داده‌اند که در ادامه به بررسی آن‌ها پرداخته می‌شود.

³⁶Module



شکل ۲-۲: روش‌های یادگیری پیوسته مبتنی بر معماری در مدل‌های زبانی بزرگ و بینایی-زبان [۲۶]



شکل ۲-۳: نمایش روش L2P در زمان آزمون [۲۷]

تنظیم پرامپت

در روش تنظیم پرامپت^{۳۷} به جای بازآموزی کامل یا تغییر در پارامترهای اصلی مدل، مجموعه‌ای از بردارهای قابل آموزش به عنوان پرامپت به ابتدای نشانه‌های ورودی^{۳۸} اضافه می‌شوند. این بردارها بدون دست‌کاری در ساختار درونی مدل، نقش راهنما را ایفا کرده و جهت‌گیری مدل در تفسیر داده‌های جدید را مشخص می‌سازند. در واقع، مدل با همان دانش قبلی خود به تحلیل ورودی می‌پردازد، اما به واسطه‌ی پرامپت‌های جدید، قادر به تطبیق با وظایف تازه می‌شود. این روش به دلیل مصرف کم منابع محاسباتی و عدم نیاز به تغییر در پارامترهای اصلی، به‌ویژه برای سناریوهایی با دسترسی محدود به مدل یا منابع، بسیار مناسب است [۲۶].

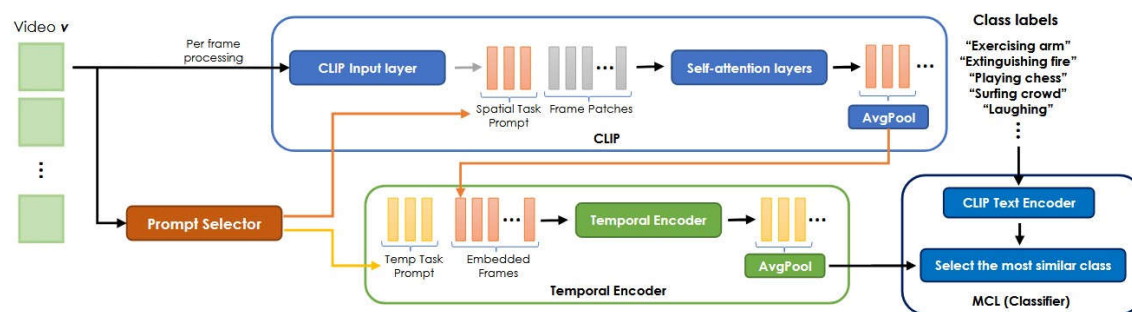
روش L2P^{۳۹} که توسط وانگ و همکاران [۲۷] ارائه شده است، یک چارچوب نوآورانه برای یادگیری پیوسته بدون نیاز به شناسایی وظیفه در زمان آزمون می‌باشد. همان‌طور که در شکل ۲-۳ مشاهده می‌شود، این روش به جای تغییر وزن‌های مدل پیش‌آمोخته، از مجموعه‌ای از پرامپت‌های یادگرفته‌ی بهره می‌برد که در یک فضای حافظه اشتراکی به نام استخر پرامپت^{۴۰} نگهداری می‌شوند. L2P از یک مکانیزم

³⁷Prompt Tuning

³⁸Input tokens

³⁹Learning to Prompt for Continual Learning

⁴⁰Prompt pool



شکل ۲-۴: نمایش روش PIVOT در زمان آزمون [۲۸]

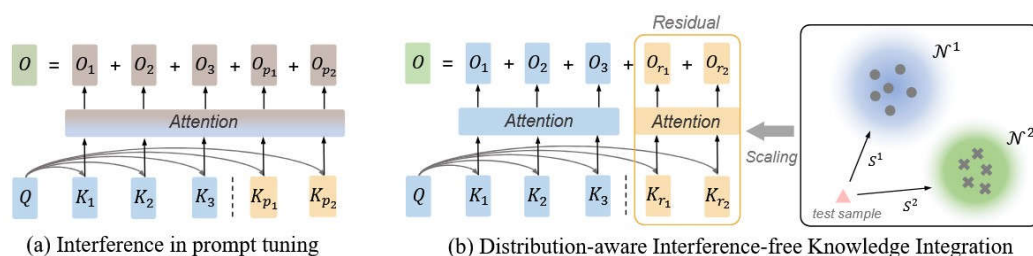
پرس وجوی مبتنی بر جفت‌های کلید-مقدار بهره می‌برد تا به صورت پویا و متناسب با ورودی، پرامپت‌های مرتبط را انتخاب کرده و به نشانه‌های ورودی مدل اضافه کند. سپس این نشانه‌های توسعه‌یافته به مدل پیش‌آمोخته تزریق شده و پیش‌بینی انجام می‌شود. در این روش، پرامپت‌ها، دانش خاص هر وظیفه یا دانش مشترک بین وظایف را به صورت فشرده ذخیره می‌کنند و باعث کاهش چشمگیر فراموشی مخرب در یادگیری وظایف متوالی می‌شوند. ساختار طراحی شده در L2P همان‌طور که در شکل ۲-۳ نشان داده شده، از یک بخش انتخاب پرامپت، لایه‌های کدگذار پیش‌آمोخته، و دسته‌بند نهایی تشکیل شده است. ویلا و همکاران [۲۸]، روشی به نام PIVOT را معرفی کرده‌اند که در آن از دانش پیش‌آموخته در مدل تصویر-متن CLIP، بهره گرفته می‌شود. این روش، همان‌طور که در شکل ۲-۴ مشاهده می‌شود، ابتدا قاب‌های ویدیو را به صورت جداگانه از طریق لایه‌های ورودی CLIP پردازش می‌کند و سپس با استفاده از کدگذار زمانی^{۴۱}، وابستگی‌های زمانی میان قاب‌ها را مدل می‌کند. PIVOT از پرامپت‌گذاری برای هر وظیفه‌ی خاص بهره می‌برد که شامل پرامپت‌های مکانی^{۴۲} و زمانی است و به مدل کمک می‌کند تا دانش مربوط به وظایف قبلی را حفظ کند و در عین حال به وظایف جدید نیز بپردازد. در این ساختار، همان‌طور که در شکل ۲-۴ نشان داده شده است، ابتدا پرامپت‌های مناسب با کمک یک انتخاب‌کننده‌ی پرامپت^{۴۳}، انتخاب شده و به ورودی‌های کدگذار مکانی و زمانی افزوده می‌شوند. در نهایت، ویژگی‌های استخراج‌شده، با استفاده از یک دسته‌بند مبتنی بر یادگیری تقابلی چندماهیتی^{۴۴}، با بردارهای متنی دسته‌ها مقایسه و دسته‌بندی می‌شوند. این روش تنها با تکیه بر دانش گسترده‌ی مدل‌های تصویر-متن، به طور موثری توانسته است عملکرد مدل‌های پیشین را در چالش‌های ویدیویی بهبود بخشد و نتایج قابل توجهی در محک‌هایی مانند vCLIMB [۲۹] کسب کند.

^{۴۱}Temporal encoder

^{۴۲}Spatial prompts

^{۴۳}Prompt selector

^{۴۴}Multi-modal Contrastive Learning (MCL)



شکل ۲-۵: مصورسازی مسئله‌ی تداخل در روش‌های تنظیم پرامپت قبلی و روش پیشنهادی DIKI در زمان آزمون [۳۰]

در راستای توسعه‌ی روش‌های یادگیری پیوسته در مدل‌های بینایی-زبان، تانگ و همکاران [۳۰]، چارچوبی با عنوان یکپارچه‌سازی دانش بدون تداخل و آگاه از توزیع^{۴۵}، را ارائه داده‌اند که هدف آن حفظ دانش پیش‌آمورخته‌ی مدل‌های بینایی-زبان در شرایط یادگیری پیوسته است. همانطور که در شکل ۲-۵ مشاهده می‌شود، این روش برخلاف روش‌های سنتی مبتنی بر پرامپت‌گذاری که منجر به تداخل اطلاعات^{۴۶} و از دست رفتن توانایی یادگیری بدون نمونه می‌شوند، یک مکانیزم توجه باقی‌مانده^{۴۷}، طراحی کرده است که باعث می‌شود دانش جدید بدون آسیب به دانش پیش‌آمورخته به مدل تزریق شود. در ساختار پیشنهادی، خروجی توجه، به دو بخش مجزا تقسیم می‌شود: یک مسیر اصلی که دانش پیش‌آمورخته مدل را دست‌نخورده نگه می‌دارد و یک مسیر باقی‌مانده که دانش جدید را به مدل اضافه می‌کند. علاوه بر این، یک مکانیزم واسنجی^{۴۸} مبتنی بر توزیع، ارائه می‌دهد که به مدل کمک می‌کند هنگام مواجه شدن با داده‌هایی از توزیع‌های ناشناخته، میزان دخالت دانش جدید را کنترل کند.

⁴⁵Distribution-aware Interference-free Knowledge Integration (DIKI)

⁴⁶Information interference

⁴⁷Residual attention

⁴⁸Calibration